Hacia el 95% de Confianza:

Monitorización y Calibración de Agentes de IA basados en RAG

Autor: Santiago Martínez Díe
Director: Francisco Ruiz Gonzalez
Codirector: Julian Jack Monís Reeves

Grado en Ingeniería Matemática e Inteligencia Artificial · ICAI · 2026

TRABAJO FIN DE GRADO

1. Motivación y Estado de la Cuestión

RAG en auge → arquitecturas heterogéneas → problema de confianza cuantificable

¿Por qué este proyecto?

Los sistemas RAG —Generación Aumentada por Recuperación— se han consolidado como la arquitectura dominante en IA empresarial generativa: permiten a los LLM acceder a información externa y reducir alucinaciones.

El problema:

Hoy existen múltiples arquitecturas RAG modernas —Agentic, Graph, SQL, Hybrid, Self-Reflective...— pero no existe ningún framework que las evalúe a todas con las mismas métricas y que produzca un indicador de confianza único, calibrado y comparable entre ellas.

La pregunta central del TFG:

¿Cuándo y cuánto podemos confiar en la respuesta de un agente RAG? ¿Y varía esa confianza según la arquitectura usada?

Tipologías RAG Modernas

No todas se analizan igual — la arquitectura determina qué métricas son más críticas

Recuperación

Reranking · Hybrid Search · Query Expansion · Multi-Query RAG

Representación del conocimiento

Knowledge Graph · Context-Aware Chunking · Late Chunking · Hierarchical RAG · Fine-tuned Embeddings

Razonamiento y generación

Agentic RAG · Self-Reflective RAG · Contextual Retrieval

2. Objetivos del Proyecto

LangChain/LangGraph como base de construcción · LangSmith como núcleo de observabilidad y evaluación

Objetivo General: Construir un framework sobre LangChain/LangGraph —el ecosistema dominante para agentes RAG— con LangSmith como núcleo de observabilidad, que evalúe cualquier arquitectura RAG con métricas automáticas y un score de confianza único calibrado y comparable.

O1

Evaluar agentes RAG existentes

Tomar arquitecturas RAG reales de repositorios (Agentic, Graph, SQL, Hybrid) y evaluarlas sobre LangSmith SDK.

O2

Métricas universales

Correctness, groundedness, answer relevance, retrieval relevance + métricas específicas por tipología RAG.

O3

Interfaz universal

Mismo código para evaluar cualquier arquitectura RAG. Wrapper sobre LangSmith SDK con evaluadores automáticos de distintos tipos —el detalle en la siguiente diapositiva.

O4

Score único calibrado

Combinar las métricas en un único porcentaje (0–100%) comparable entre arquitecturas heterogéneas.

O5

Validación empírica

Comparar arquitecturas y validar el framework en un caso empresarial real.

3. Metodología — Framework y Métricas

LangSmith SDK como núcleo · evaluadores LLM-as-judge y modelos NLI · métricas universales y por tipología

Capas del Framework

Agentes RAG (existentes)

Repositorios públicos · Agentic · Graph · SQL · Hybrid

LangSmith SDK ← núcleo

Trazas · datasets · evaluadores · observabilidad

Evaluadores automáticos

LLM-as-judge · Modelos NLI (DeBERTa/RoBERTa) · Métricas lexicales

Score de confianza calibrado

Combinación calibrada → único % comparable entre arquitecturas

Métricas de Evaluación

Universales (todas las arquitecturas)

Correctness

¿La respuesta es factualmente correcta?

Groundedness

¿Fundamentada en el contexto recuperado?

Answer Relevance

¿Responde a lo que se preguntó?

Retrieval Relevance

¿Los documentos recuperados son pertinentes?

Próximo paso: métricas por tipología — Rerank Stability, validez SQL, calidad Cypher (Graph RAG)...

4. Plan de Trabajo — Fases y Cronograma

Fechas concretas · Feb 2026 → May 2026 · 6 fases desde la situación actual

F0 ✓ Dic 2025 – Ene 2026	F1+F2 18 Feb – 9 Mar	F3 10 Mar – 23 Mar	F4 24 Mar – 13 Abr	F5 14 Abr – 11 May	F6 12 May – 31 May
Investigación y familiarización	**Agentes RAG + Métricas**	**Esqueleto del framework**	**Calibración y conexión**	**Validación y extensión**	**Redacción y defensa**
Papers métricas RAG, arquitecturas estado del arte, docs LangSmith SDK, LangChain, LangGraph (web, YouTube, tutoriales). COMPLETADA.	Implementar y evaluar arquitecturas RAG reales desde repositorios con LangSmith. Definir y testear los evaluadores: LLM-as-judge, modelos NLI y métricas lexicales.	Construir la interfaz universal (frontend): wrapper común, API estandarizada sobre LangSmith SDK válida para cualquier arquitectura RAG.	Conectar métricas (F1+F2) con la interfaz (F3). Implementar la calibración: combinación ponderada → score único 0–100% entre arquitecturas.	Caso empresarial real. Comparación objetiva entre arquitecturas. Añadir métricas específicas por tipología (Rerank Stability, SQL, Cypher…).	Documentación completa del TFG. Preparación y defensa ante tribunal.
	◀ AHORA				

5. Estado Actual del Proyecto

Situación a 18 de febrero de 2026 · inicio de F1+F2

Estado Actual del Proyecto

✓ **Revisión bibliográfica**

Papers métricas RAG, arquitecturas modernas, docs LangSmith SDK, LangChain y LangGraph.

✓ **Entorno técnico configurado**

LangChain, LangGraph y LangSmith SDK operativos. APIs de LLMs y plataformas listas.

✓ **Arquitecturas RAG identificadas**

Repositorios públicos seleccionados cubriendo Agentic, Graph, SQL, Hybrid y otras tipologías.

... **Probando agentes RAG reales**

Evaluando arquitecturas con LangSmith, buscando la forma más eficiente de analizar cada tipología. ← AHORA

... **Evaluadores LLM-as-judge**

Próximo: correctness, groundedness, relevance y retrieval relevance como componentes reutilizables.

Conclusión y Próximos Pasos

RAG se ha convertido en la arquitectura dominante — pero evaluar arquitecturas heterogéneas de forma comparable es un problema abierto.

LangSmith SDK es el núcleo. El framework añade lo que falta: interfaz universal + evaluadores LLM-as-judge + score calibrado único.

El score único (0–100%) permite comparar Agentic RAG vs Graph RAG vs SQL RAG con total objetividad. Eso no existe hoy.

Estado actual: probando arquitecturas reales. Próximo paso: construir el esqueleto de la interfaz universal (F3, 10–23 marzo).

¿Preguntas?